

前馈神经网络实验报告

1911433 林坤

一、实验要求

- 掌握 PyTorch 框架基础算子操作
- 学会使用 PyTorch 搭建简单的前馈神经网络来训练 MNIST 数据集
- 了解如何改进网络结构、调试参数以提升网络识别性能

二、实验内容

实验内容部分主要是记录了对不同网络结构和超参数的调整过程，和原始版本结果进行对比，为改进 MLP 网络提供对照。

(一) 原始版本 MLP

1. 网络结构

老师提供的原始版本 MLP 网络结构如下所示：

```
1 Net(  
2     (fc1) : Linear(in_features=784, out_features=50, bias=True)  
3     (fc1_drop) : Dropout(p=0.2, inplace=False)  
4     (fc2) : Linear(in_features=50, out_features=50, bias=True)  
5     (fc2_drop) : Dropout(p=0.2, inplace=False)  
6     (fc3) : Linear(in_features=50, out_features=10, bias=True)  
7 )
```


其中各层网络如下：

- 输入层：以 28*28 一个图片规模大小输入全连接至 50 个输出
- Relu 激活函数
- 一层隐藏层：以 50 点输入 50 点输出
- Relu 激活函数
- 输出层：以 50 点输入 10 点输出


- 以 `log_softmax` 函数求出最大值 (最大概率分类) 作为输出

2. MNIST 验证集上 loss 和 accuracy 曲线

原始版本 MLP 在在 MNIST 验证集上的 loss 曲线如下图所示：



原始版本 MLP 在在 MNIST 验证集上的 accuracy 曲线如下图所示：



原始 MLP 网络结构在 10 epochs 下，Average loss 为 0.1238，Accuracy 为 9627/10000 (96%)，耗时 1min 36s。



(二) 改进 MLP 网络结构

1. 增加网络宽度


在原有网络结构不变情况下，增加网络宽度。第二层网络两端宽度由 50 增加到 200

第二层网络宽度增加到 200 的预测结果如下：



5 epochs，损失曲线和准确率曲线如下：



10 epochs，损失曲线和准确率曲线如下：



20 epochs，损失曲线和准确率曲线如下：



结果总结如下：

- 5 epochs: Average loss: 0.1283, Accuracy: 9633/10000 (96%) –56.6 s
- 10 epochs: Average loss: 0.0846, Accuracy: 9721/10000 (97%) –1min 57s
- 20 epochs: Average loss: 0.0620, Accuracy: 9829/10000 (98%) –4min 9s

2. 加深网络深度



在原有网络宽度不变情况下 (第二层两端均 50)，增加网络 1 层，其中增加的网络层两端仍为 50 宽度 (在增加的网络层后同样加入 Dropout(0.2) 优化层)。修改的网络结构代码如下：

```



1 class Net(nn.Module):
2     def __init__(self):
3         super(Net, self).__init__()
4         self.fc1 = nn.Linear(28*28, 50)
5         self.fc1_drop = nn.Dropout(0.2)
6         self.fc2 = nn.Linear(50, 50)
7         self.fc2_drop = nn.Dropout(0.2)
8         self.fc3 = nn.Linear(50, 50)
9         self.fc3_drop = nn.Dropout(0.2)
10        self.fc4 = nn.Linear(50, 10)
11
12    def forward(self, x):
13        x = x.view(-1, 28*28)
14        x = F.relu(self.fc1(x))
15        x = self.fc1_drop(x)
16        x = F.relu(self.fc2(x))
17        x = self.fc2_drop(x)
18        x = F.relu(self.fc3(x))
19        x = self.fc3_drop(x)
20        return F.log_softmax(self.fc4(x), dim=1)

```


5 epochs, 损失曲线和准确率曲线如下:



10 epochs, 损失曲线和准确率曲线如下:



20 epochs, 损失曲线和准确率曲线如下:



结果总结如下:

- 5 epochs: Average loss: 0.1668, Accuracy: 9513/10000 (95.1%) –53 s
- 10 epochs: Average loss: 0.1273, Accuracy: 9629/10000 (96.3%) –1min 48s
- 20 epochs: Average loss: 0.1116, Accuracy: 9679/10000 (96.8%) –3min 42s

可以看到, 在增加了一层网络后, 网络准确率没有增加反而比原始网络准确率低, 为了验证是否是因为增加层数过少的情况, 这里对网络再进一步加深, 即在原始网络基础上增加三层相同的隐藏层。网络结构代码如下:


```
1 class Net(nn.Module):
2     def __init__(self):
3         super(Net, self).__init__()
4         self.fc1 = nn.Linear(28*28, 50)
5         self.fc1_drop = nn.Dropout(0.2)
6         self.fc2 = nn.Linear(50, 50)
7         self.fc2_drop = nn.Dropout(0.2)
8         self.fc3 = nn.Linear(50, 50)
9         self.fc3_drop = nn.Dropout(0.2)
10        self.fc4 = nn.Linear(50, 50)
11        self.fc4_drop = nn.Dropout(0.2)
12        self.fc5 = nn.Linear(50, 50)
13        self.fc5_drop = nn.Dropout(0.2)
14        self.fc6 = nn.Linear(50, 10)
15
16    def forward(self, x):
17        x = x.view(-1, 28*28)
18        x = F.relu(self.fc1(x))
19        x = self.fc1_drop(x)
20        x = F.relu(self.fc2(x))
```

```


21         x = self.fc2_drop(x)
22         x = F.relu(self.fc3(x))
23         x = self.fc3_drop(x)
24         x = F.relu(self.fc4(x))
25         x = self.fc4_drop(x)
26         x = F.relu(self.fc5(x))
27         x = self.fc5_drop(x)
28         return F.log_softmax(self.fc6(x), dim=1)

```

分别在 5、10、20 epochs 下的 loss 曲线如下：



分别在 5、10、20 epochs 下的 accuracy 曲线如下：



结果总结如下：

- 5 epochs: Average loss: 0.3079, Accuracy: 9294/10000 (92.9%) –52.4 s
- 10 epochs: Average loss: 0.1738, Accuracy: 9578/10000 (95.8%) –1min 47s
- 20 epochs: Average loss: 0.1536, Accuracy: 9624/10000 (96.2%) –3min 46s

(三) 使用不同激活函数

pytorch 中提供的激活函数有很多，这里尝试改为两个经典的激活函数 sigmoid 和 Tanh

1. sigmoid 激活函数

在原始版本的网络结构中，将 Relu 激活函数改为 sigmoid，其它结构不变，forward 函数代码如下：

```

1 def forward ( self , x ) :


```

```


2     x = x.view(-1, 28 28)
3     x = torch.sigmoid(self.fc1(x))
4     x = self.fc1_drop(x)
5     x = torch.sigmoid(self.fc2(x))
6     x = self.fc2_drop(x)
7     return F.log_softmax(self.fc3(x),dim=1)

```

在 5、10、20 epochs 下的 loss 曲线如下：



分别在 5、10、20 epochs 下的 accuracy 曲线如下：



结果总结如下：

- 5 epochs: Average loss: 0.7940, Accuracy: 7589/10000 (75.9%) - 51.7 s
- 10 epochs: Average loss: 0.4368, Accuracy: 8806/10000 (88.1%) - 1min 34s
- 20 epochs: Average loss: 0.2926, Accuracy: 9159/10000 (91.6%) - 3min 12s

2. Tanh 激活函数


在原始版本的网络结构中，将 Relu 激活函数改为 Tanh，其它结构不变，forward 函数代码如下：

```


1 def forward ( self , x ) :
2     x = x.view(-1, 28 28)
3     x = torch.tanh(self.fc1(x))
4     x = self.fc1_drop(x)
5     x = torch.tanh(self.fc2(x))
6     x = self.fc2_drop(x)
7     return F.log_softmax(self.fc3(x),dim=1)

```

分别在 5、10、20 epochs 下的 loss 曲线如下：



分别在 5、10、20 epochs 下的 accuracy 曲线如下：




结果总结如下：

- 5 epochs: Average loss: 0.2081, Accuracy: 9381/10000 (93.8%) - 48.9 s
- 10 epochs: Average loss: 0.1556, Accuracy: 9523/10000 (95.2%) - 1min 37s
- 20 epochs: Average loss: 0.1196, Accuracy: 9639/10000 (96.4%) - 3min 18s


(四) 不同学习率

1. 增大学习率

增加学习率由原有的 0.01 增加至 0.025，分别在 5、10、20 epochs 下的 loss 曲线如下：



在 5、10、20 epochs 下的 accuracy 曲线如下：




结果总结如下：


- 5 epochs: Average loss: 0.1314, Accuracy: 9603/10000 (96.0%) –46 s
- 10 epochs: Average loss: 0.1059, Accuracy: 9679/10000 (96.8%) –1min 39s
- 20 epochs: Average loss: 0.0935, Accuracy: 9707/10000 (97.1%) –3min 4s

2. 减小学习率

减小学习率由原有的 0.01 减小至 0.005，分别在 5、10、20 epochs 下的 loss 曲线如下：



分别在 5、10、20 epochs 下的 accuracy 曲线如下：




结果总结如下：

- 5 epochs: Average loss: 0.2300, Accuracy: 9310/10000 (93.1%) –47.7 s
- 10 epochs: Average loss: 0.1669, Accuracy: 9502/10000 (95.0%) –1min 35s
- 20 epochs: Average loss: 0.1187, Accuracy: 9637/10000 (96.4%) - 3min 14s


(五) 不同 dropout 率

1. 增大 dropout 率

增加 dropout 率由原有的 0.2 增加至 0.35，分别在 5、10、20 epochs 下的 loss 曲线如下：



分别在 5、10、20 epochs 下的 accuracy 曲线如下：




结果总结如下：


- 5 epochs: Average loss: 0.1980, Accuracy: 9416/10000 (94.2%) –45.4 s
- 10 epochs: Average loss: 0.1509, Accuracy: 9558/10000 (95.6%) –1min 44s
- 20 epochs: Average loss: 0.1274, Accuracy: 961/10000 (96.1%) –3min 17s

2. 减小 dropout 率

减小 dropout 率由原有的 0.2 减小至 0.05，分别在 5、10、20 epochs 下的 loss 曲线如下：



分别在 5、10、20 epochs 下的 accuracy 曲线如下：




结果总结如下：

- 5 epochs: Average loss: 0.1595, Accuracy: 953/10000 (95.3%) –44.7 s
- 10 epochs: Average loss: 0.1107, Accuracy: 964/10000 (96.4%) –1min 34s
- 20 epochs: Average loss: 0.0868, Accuracy: 972/10000 (97.2%) –3min 28s


(六) 不同 momentum

1. 增大动量

增大 momentum 由原来的 0.5 增大至 0.7。分别在 5、10、20 epochs 下的 loss 曲线如下：



分别在 5、10、20 epochs 下的 accuracy 曲线如下：




结果总结如下：


- 5 epochs: Average loss: 0.1366, Accuracy: 9584/10000 (95.8%) - 47.4 s
- 10 epochs: Average loss: 0.1040, Accuracy: 9667/10000 (96.7%) - 1min 37s
- 20 epochs: Average loss: 0.0907, Accuracy: 9720/10000 (97.2%) - 3min 25s

2. 减小动量

减小 momentum 由原来的 0.5 减小至 0.3。分别在 5、10、20 epochs 下的 loss 曲线如下：



分别在 5、10、20 epochs 下的 accuracy 曲线如下：



结果总结如下：

- 5 epochs: Average loss: 0.1926, Accuracy: 9449/10000 (94.5%) - 49.5 s
- 10 epochs: Average loss: 0.1368, Accuracy: 9589/10000 (95.9%) - 1min 43s
- 20 epochs: Average loss: 0.1157, Accuracy: 9654/10000 (96.5%) - 3min 41s

三、 总体改进与分析

1. 网络宽度

增加网络宽度，将隐层的神经元个数从 50 增加至 200，训练后发现准确率从 96.2% 增加至 97%，并且当 epochs 增加到 20 时，准确率进一步提升达到了 98%。说明适当增加网络宽度，可以让网络层学习到更多特征，提升网络预测准确率。在训练耗时方面，增加网络宽度同时也会增加训练时间。

2. 网络深度

第一次增加了一层网络深度，准确率从 96.2%(原始网络) 变为 96.3%，变化不大；在尝试了加深网络深度后 (增加三层网络)，发现准确率不增反降，从 96.2%(原始网络) 降至 95.8%。说明一味地增加网络深度并不能提升预测准确率。在网络能够收敛的前提下，只是简单增加神经网络的深度并不一定可以获得更好的效果，反而有可能出现网络退化的情况，正确率不增反降，正如奥卡姆剃刀原理所述。在训练耗时方面，增加网络深度会稍微增加训练时间。

3. 不同激活函数

sigmoid: 从测试的曲线图可以发现, 在使用该激活函数时5、10、20 epochs 下的准确率仅有75.9%、88.1%、91.6%, 说明使用 sigmoid 激活函数收敛缓慢。除此之外, loss 和 accuracy 曲线往后斜率非常小, 说明 sigmoid 函数容易出现变化太缓慢, 导数接近 0 的梯度消失情况。

Tanh: 从实验曲线图可以看到, 使用 sigmoid 激活函数时, 5、10、20 epochs 下的准确率为93.8%、95.2%、96.4%, 相较于 sigmoid 收敛速度快, Tanh 是 sigmoid 的变式, 因为 Tanh改善了 sigmoid 的输出, 均值为 0, 缓解了收敛缓慢的问题。但对于预测准确率来说, 相较于原始版的 Relu, 几乎没有什么提升。在训练耗时方面, 使用不同激活函数基本不会影响训练时间, 训练时间非常接近。

4. 学习率

增大学习率: 网络训练收敛速度加快; 但从 20 epochs 曲线图可以看到, 在训练接近尾声时, loss 和 accuracy 曲线上下波动很大。说明学习率过大会导致最终网络的收敛效果不好, 反复在最优值附近徘徊。预测准确率略高于原始版本。

减小学习率: 网络收敛速度变缓, 在训练接近尾声时, loss 和 accuracy 曲线越来越平滑, 逐渐收敛。但如果学习率过小, 容易导致网络陷入局部极值点影响预测准确率。预测准确率略低于原始版本。在训练耗时方面, 不同学习率基本不影响训练时间。

5.dropout 率

第一次增大 dropout 率至 0.35, 第二次减少 dropout 率至 0.05, 比对两次实验的 loss 变化曲线, 可以看到 0.35 dropout 率的 loss 下降速率明显慢于 0.05 dropout 率。可以发现 dropout 率越大每轮训练舍弃的信息越多, loss 下降越慢, accuracy 提升也越慢。dropout 作为一种正则化方法, 缓解了过拟合的情况发生, 但过大的 dropout 率拖慢收敛速度, 需要不断调试至合适的 dropout 率 (最好不要超过 0.5)。需要考虑训练 epochs 轮数多少, 判断较大的 dropout 率下是否能够充分收敛。

6.momentum 动量

加入 momentum 为了在一定程度上避免陷入局部最优解的情况, momentum 越大就越有可能摆脱局部凹区域。对比增大动量至 0.7 和减少动量至 0.3 的 loss 曲线图可以看到, momentum 越大, loss 下降得越快, 且每轮的 loss 和 accuracy 波动较大。0.7 动量的准确率略高于原始网络, 0.3 动量准确率略低于原始网络。

最终代码:

综合以上实验结果分析可知, 我们可以通过加大网络宽度, 网络深度不变, 使用 Relu 激活函数, 增加学习率, 适量减小 dropout 率, 适量改变并增加 momentum 的改进策略。最终的选取网络结构如下:

```
1 class Net(nn.Module):
2     def __init__(self):
3         super(Net, self).__init__()
4         self.fc1 = nn.Linear(28*28, 28*28)
5         self.fc1_drop = nn.Dropout(0.15)
6         self.fc2 = nn.Linear(28*28, 28*28)
7         self.fc2_drop = nn.Dropout(0.15)
8         self.fc3 = nn.Linear(28*28, 10)
9
10    def forward(self, x):
11        x = x.view(-1, 28*28)
12        x = F.relu(self.fc1(x))
13        x = self.fc1_drop(x)
14        x = F.relu(self.fc2(x))
15        x = self.fc2_drop(x)
16        return F.log_softmax(self.fc3(x), dim=1)
17
18 model = Net().to(device)
19 optimizer = torch.optim.SGD(model.parameters(), lr = 0.015, momentum = 0.6)
20 criterion = nn.CrossEntropyLoss()
```